Universidad Nacional de Colombia Sede Medellín

Aprendizaje Automático

Taller 1

Datos, modelos lineales y decisiones bajo incertidumbre

Estudiantes: David Delgado Ortiz
José Daniel Moreno Ceballos

Profesor: Alejandro Vasquez Echeverri

Año: 2026

16 de octubre de 2026

Índice

Notación y convenciones **2**

1. Parte I. Fundamentación teórica **2**

1.1. Problema 1. Mínimos cuadrados, Ridge y estabilidad . . . 2

a) Verosimilitud y ecuaciones normales . . . 2

b) Unicidad y proyección . . . 3

c) Sesgo y varianza de Ridge . . . 5

1.2. Problema 2. Lasso, esparsidad y representación . . . 7

a) Caso ortogonal y umbral suave . . . 7

b) Optimalidad y columnas duplicadas . . . 10

c) Escalado y regularización . . . 12

1.3. Problema 3. Probabilidades, ponderación y decisiones . . . 13

a) Verosimilitud, Hessiano y estabilidad . . . 13

b) Decisión con costos asimétricos . . . 17

c) Ponderación de clases . . . 19

2. Parte II. Implementación y experimentación **21**

2.1. Problema 4. Modelos desde cero y verificación numérica . . . 21

Decisiones metodológicas . . . 21

Resultados esenciales . . . 21

Conclusiones . . . 22

2.2. Problema 5. Simulación de sesgo, varianza y selección . . . 22

Decisiones metodológicas . . . 22

Resultados esenciales . . . 23

Conclusiones . . . 23

2.3. Problema 6. Regresión reproducible sobre Airfoil . . . 23

Decisiones metodológicas . . . 23

Resultados esenciales . . . 25

Conclusiones . . . 26

2.4. Problema 7. Clasificación temporal y política de alertas . . . 26

Decisiones metodológicas . . . 26

Resultados esenciales . . . 27

Conclusiones . . . 28

3. Conclusiones generales **28**

Notación y convenciones

Sea $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$, $X \in \mathbb{R}^{N\times D}$, $\mathbf{w} \in \mathbb{R}^D$, $b \in \mathbb{R}$.

$$z = X\mathbf{w} + b\mathbf{1}_N, \qquad p_n = \sigma(z_n) = \frac{1}{1+e^{-z_n}}, \tag{1}$$

$$J_{\text{reg}}(\mathbf{w}, b) = \frac{1}{2N}\,\|z - \mathbf{y}\|_2^2\,, \tag{2}$$

$$F(\mathbf{w}, b) = J(\mathbf{w}, b) + \lambda_1\,\|\mathbf{w}\|_1 + \frac{\lambda_2}{2}\,\|\mathbf{w}\|_2^2\,, \qquad \lambda_1, \lambda_2 \geq 0. \tag{3}$$

1. Parte I. Fundamentación teórica

1.1. Problema 1. Mínimos cuadrados, Ridge y estabilidad

Pregunta central. ¿Cómo puede aumentar el sesgo y, aun así, mejorar la estimación?

a) Log-verosimilitud, gradiente, Hessiano y ecuaciones normales de Ridge

Derivar la log-verosimilitud gaussiana, relacionarla con (2) y obtener gradiente, Hessiano y ecuaciones normales de Ridge con $\tilde{X} = [\mathbf{1}_N\ X]$, $\boldsymbol{\theta} = (b, \mathbf{w}^\top)^\top$, $P = \text{diag}(0, 1, \ldots, 1)$.

Parte 1: log-verosimilitud.

Paso 1: la verosimilitud. Por independencia condicional, la verosimilitud es el producto de las densidades y su logaritmo es la suma de los logaritmos:

$$\ell(\boldsymbol{\theta}) = \sum_{n=1}^{N} \log \mathcal{N}(y_n \mid \boldsymbol{w}^\top \boldsymbol{x}_n + b, \sigma^2) = -\frac{N}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\sum_{n=1}^{N}(y_n - \boldsymbol{w}^\top \boldsymbol{x}_n - b)^2.$$

Como $\boldsymbol{w}^\top \boldsymbol{x}_n + b = z_n = (\widetilde{X}\boldsymbol{\theta})_n$, en forma matricial

$$\ell(\boldsymbol{\theta}) = -\frac{N}{2}\log(2\pi\sigma^2) - \frac{1}{2\sigma^2}\|\boldsymbol{y} - \widetilde{X}\boldsymbol{\theta}\|_2^2.$$

Paso 2: relación con (2). Como $J_{\text{reg}}(\boldsymbol{w}, b) = \frac{1}{2N}\|\boldsymbol{z} - \boldsymbol{y}\|_2^2$,

$$\ell(\boldsymbol{\theta}) = -\frac{N}{2}\log(2\pi\sigma^2) - \frac{N}{\sigma^2}\,J_{\text{reg}}(\boldsymbol{w}, b).$$

El primer término no depende de $\boldsymbol{\theta}$ y el factor N/σ^2 es positivo, luego maximizar ℓ equivale a minimizar J_{reg}: el estimador de máxima verosimilitud es OLS. Si además se pone un prior $\boldsymbol{w} \sim \mathcal{N}(\mathbf{0}, \tau^2 I_D)$ (sin prior sobre b), el MAP minimiza

$$-\frac{\sigma^2}{N}\big(\ell(\boldsymbol{\theta}) + \log p(\boldsymbol{w})\big) \;\propto\; J_{\text{reg}}(\boldsymbol{w}, b) + \frac{\lambda_2}{2}\|\boldsymbol{w}\|_2^2, \qquad \lambda_2 = \frac{\sigma^2}{N\tau^2},$$

que es la función F de (4) con $\lambda_1 = 0$ (Ridge).

Parte 2: Ridge con la convención (4). Con $\lambda_1 = 0$ y como $\|\boldsymbol{w}\|_2^2 = \boldsymbol{\theta}^\top P \boldsymbol{\theta}$,

$$F(\boldsymbol{\theta}) = \frac{1}{2N}\|\boldsymbol{y} - \widetilde{X}\boldsymbol{\theta}\|_2^2 + \frac{\lambda_2}{2}\boldsymbol{\theta}^\top P \boldsymbol{\theta}.$$

Paso 1: gradiente. Expandiendo,

$$F(\boldsymbol{\theta}) = \frac{1}{2N}\Big(\boldsymbol{y}^\top \boldsymbol{y} - 2\boldsymbol{\theta}^\top \widetilde{X}^\top \boldsymbol{y} + \boldsymbol{\theta}^\top \widetilde{X}^\top \widetilde{X}\boldsymbol{\theta}\Big) + \frac{\lambda_2}{2}\boldsymbol{\theta}^\top P \boldsymbol{\theta}.$$

Como $\widetilde{X}^\top \widetilde{X}$ y P son simétricas,

$$\nabla F(\boldsymbol{\theta}) = \frac{1}{N}(\widetilde{X}^\top \widetilde{X}\boldsymbol{\theta} - \widetilde{X}^\top \boldsymbol{y}) + \lambda_2 P\boldsymbol{\theta} = -\frac{1}{N}\widetilde{X}^\top(\boldsymbol{y} - \widetilde{X}\boldsymbol{\theta}) + \lambda_2 P\boldsymbol{\theta}.$$

Paso 2: Hessiano. Derivando otra vez respecto a $\boldsymbol{\theta}$,

$$\nabla^2 F(\boldsymbol{\theta}) = \frac{1}{N}\widetilde{X}^\top \widetilde{X} + \lambda_2 P.$$

Es simétrica y semidefinida positiva, luego F es convexa. Por el punto (b), con $\lambda_2 > 0$ y $N \geq 1$ el núcleo de $\widetilde{X}^\top \widetilde{X} + N\lambda_2 P$ es trivial, así que el Hessiano es definida positiva, F es estrictamente convexa y tiene un único minimizador.

Paso 3: ecuaciones normales. Igualando el gradiente a cero y multiplicando por N,

$$(\widetilde{X}^\top \widetilde{X} + N\lambda_2 P)\boldsymbol{\theta} = \widetilde{X}^\top \boldsymbol{y}, \qquad \widehat{\boldsymbol{\theta}}_{\text{Ridge}} = (\widetilde{X}^\top \widetilde{X} + N\lambda_2 P)^{-1}\widetilde{X}^\top \boldsymbol{y}.$$

Parte 3: dimensiones.

$\boldsymbol{y},\ \boldsymbol{z},\ \boldsymbol{r}$	$N \times 1$
X	$N \times D$
$\widetilde{X}$	$N \times (D+1)$
$\boldsymbol{\theta}$	$(D+1) \times 1$
$\boldsymbol{w}$	$D \times 1$
$b,\ \sigma^2,\ \lambda_2,\ \ell,\ F$	escalares
$P,\ \widetilde{X}^\top \widetilde{X},\ \nabla^2 F$	$(D+1) \times (D+1)$
$\nabla F,\ \widetilde{X}^\top \boldsymbol{y}$	$(D+1) \times 1$

b) Unicidad y proyección

Unicidad de OLS; unicidad de Ridge con columnas dependientes; comparar $\tilde{X}^\top r$ en OLS y Ridge; ¿es Ridge una proyección ortogonal?

b) Sea $\widetilde{X} = [\mathbf{1}_N\ X] \in \mathbb{R}^{N\times(D+1)}$, $\boldsymbol{\theta} = (b, \boldsymbol{w}^\top)^\top \in \mathbb{R}^{D+1}$ y $P = \operatorname{diag}(0, 1, \ldots, 1) \in \mathbb{R}^{(D+1)\times(D+1)}$.

Parte 1: unicidad de OLS. Las ecuaciones normales son $\widetilde{X}^\top \widetilde{X}\,\boldsymbol{\theta} = \widetilde{X}^\top \boldsymbol{y}$.

Paso 1: $\mathrm{Nul}(\widetilde{X}^\top \widetilde{X}) = \mathrm{Nul}(\widetilde{X})$**.**
($\subseteq$) Sea $\boldsymbol{t}_2 \in \mathrm{Nul}(\widetilde{X}^\top \widetilde{X})$. Multiplicando $\widetilde{X}^\top \widetilde{X}\boldsymbol{t}_2 = \mathbf{0}$ por $\boldsymbol{t}_2^\top$:

$$\boldsymbol{t}_2^\top \widetilde{X}^\top \widetilde{X}\boldsymbol{t}_2 = \|\widetilde{X}\boldsymbol{t}_2\|^2 = 0 \implies \widetilde{X}\boldsymbol{t}_2 = \mathbf{0}.$$

($\supseteq$) Sea $\boldsymbol{t}_1 \in \mathrm{Nul}(\widetilde{X})$. Entonces

$$\widetilde{X}^\top \widetilde{X}\boldsymbol{t}_1 = \widetilde{X}^\top(\widetilde{X}\boldsymbol{t}_1) = \widetilde{X}^\top \mathbf{0} = \mathbf{0}.$$

Paso 2: invertibilidad. Como $\widetilde{X}^\top \widetilde{X}$ es cuadrada de tamaño $(D+1) \times (D+1)$,

$$\widetilde{X}^\top \widetilde{X} \text{ invertible} \iff \mathrm{Nul}(\widetilde{X}^\top \widetilde{X}) = \{\mathbf{0}\} \iff \mathrm{Nul}(\widetilde{X}) = \{\mathbf{0}\} \iff \text{las columnas de } \widetilde{X} \text{ son LI.}$$

Conclusión. La solución de OLS es única si y solo si las columnas de $\widetilde{X}$ son linealmente independientes. En ese caso $\widehat{\boldsymbol{\theta}}_{\mathrm{OLS}} = (\widetilde{X}^\top \widetilde{X})^{-1}\widetilde{X}^\top \boldsymbol{y}$.

Si X tiene columnas dependientes, existe $\boldsymbol{u} \neq \mathbf{0}$ con $X\boldsymbol{u} = \mathbf{0}$. Con $\boldsymbol{t}_1 = (0, \boldsymbol{u}^\top)^\top \neq \mathbf{0}$ se tiene $\widetilde{X}\boldsymbol{t}_1 = \mathbf{0}$ y, por el paso 1, $\boldsymbol{t}_1 \in \mathrm{Nul}(\widetilde{X}^\top \widetilde{X})$. Si $\widehat{\boldsymbol{\theta}}$ es solución, también lo es $\widehat{\boldsymbol{\theta}} + s\boldsymbol{t}_1$ para todo $s \in \mathbb{R}$:

$$\widetilde{X}^\top \widetilde{X}(\widehat{\boldsymbol{\theta}} + s\boldsymbol{t}_1) = \widetilde{X}^\top \boldsymbol{y} + s\,\mathbf{0} = \widetilde{X}^\top \boldsymbol{y}.$$

Luego OLS tiene infinitas soluciones.

Parte 2: unicidad de Ridge con columnas dependientes. Sea $M = \widetilde{X}^\top \widetilde{X} + \lambda_2 P$, con $\lambda_2 > 0$ y $N \geq 1$. Las ecuaciones normales de Ridge son $M\boldsymbol{\theta} = \widetilde{X}^\top \boldsymbol{y}$.

Paso 1: $\mathrm{Nul}(M) = \{\mathbf{0}\}$**.** Sea $\boldsymbol{t} = (t_0, t_1, \ldots, t_D)^\top \in \mathrm{Nul}(M)$. Multiplicando $M\boldsymbol{t} = \mathbf{0}$ por $\boldsymbol{t}^\top$:

$$\|\widetilde{X}\boldsymbol{t}\|^2 + \lambda_2\,(t_1^2 + \cdots + t_D^2) = 0.$$

Ambos sumandos son no negativos y suman 0, luego ambos son 0:

(A) $\|\widetilde{X}\boldsymbol{t}\|^2 = 0 \Rightarrow \widetilde{X}\boldsymbol{t} = \mathbf{0}$.

(B) $\lambda_2(t_1^2 + \cdots + t_D^2) = 0$ y, como $\lambda_2 > 0$, $t_1 = \cdots = t_D = 0$.

Por (B), $\boldsymbol{t} = (t_0, 0, \ldots, 0)^\top$, y (A) se reduce a

$$\widetilde{X}\boldsymbol{t} = t_0\,\mathbf{1}_N = \mathbf{0}.$$

Cada entrada de $t_0\mathbf{1}_N$ es t_0 y, como $N \geq 1$, existe al menos una entrada; luego $t_0 = 0$. Así $\boldsymbol{t} = \mathbf{0}$.

Paso 2: unicidad. M es cuadrada y de núcleo trivial, luego es invertible. Además, si $\boldsymbol{\theta}_1, \boldsymbol{\theta}_2$ resuelven $M\boldsymbol{\theta} = \widetilde{X}^\top \boldsymbol{y}$, entonces $M(\boldsymbol{\theta}_1 - \boldsymbol{\theta}_2) = \mathbf{0}$, o sea $\boldsymbol{\theta}_1 - \boldsymbol{\theta}_2 \in \mathrm{Nul}(M) = \{\mathbf{0}\}$ y $\boldsymbol{\theta}_1 = \boldsymbol{\theta}_2$. La solución es

$$\widehat{\boldsymbol{\theta}}_{\mathrm{Ridge}} = (\widetilde{X}^\top \widetilde{X} + \lambda_2 P)^{-1}\widetilde{X}^\top \boldsymbol{y}.$$

Contraste con OLS. Con el $\boldsymbol{t}_1 = (0, \boldsymbol{u}^\top)^\top$ de la dependencia,

$$M\boldsymbol{t}_1 = \widetilde{X}^\top \widetilde{X}\boldsymbol{t}_1 + \lambda_2 P\boldsymbol{t}_1 = \mathbf{0} + \lambda_2 \begin{pmatrix} 0 \\ \boldsymbol{u} \end{pmatrix} \neq \mathbf{0},$$

así que $\boldsymbol{t}_1 \notin \mathrm{Nul}(M)$: la penalización elimina el movimiento gratis de OLS.

Conclusión. Ridge conserva la unicidad aun cuando X tiene columnas dependientes y aun sin penalizar b. En ningún paso se usó la independencia de las columnas de X: los pesos los fija $\lambda_2 > 0$ y el intercepto lo fija la columna de unos con $N \geq 1$.

Parte 3: residuo y ortogonalidad. Sea $\boldsymbol{r} = \boldsymbol{y} - \widetilde{X}\widehat{\boldsymbol{\theta}}$.

OLS. De $\widetilde{X}^\top \widetilde{X}\widehat{\boldsymbol{\theta}} = \widetilde{X}^\top \boldsymbol{y}$,

$$\widetilde{X}^\top(\boldsymbol{y} - \widetilde{X}\widehat{\boldsymbol{\theta}}) = \mathbf{0} \quad \Longrightarrow \quad \widetilde{X}^\top \boldsymbol{r} = \mathbf{0}.$$

Ridge. De $(\widetilde{X}^\top \widetilde{X} + \lambda_2 P)\widehat{\boldsymbol{\theta}} = \widetilde{X}^\top \boldsymbol{y}$,

$$\lambda_2 P\widehat{\boldsymbol{\theta}} = \widetilde{X}^\top(\boldsymbol{y} - \widetilde{X}\widehat{\boldsymbol{\theta}}) = \widetilde{X}^\top \boldsymbol{r}.$$

Con $\widehat{\boldsymbol{\theta}} = (\widehat{b}, \widehat{\boldsymbol{w}}^\top)^\top$,

$$\widetilde{X}^\top \boldsymbol{r} = \lambda_2 \begin{pmatrix} 0 \\ \widehat{\boldsymbol{w}} \end{pmatrix}, \qquad \text{es decir,} \qquad \mathbf{1}_N^\top \boldsymbol{r} = 0, \quad X^\top \boldsymbol{r} = \lambda_2 \widehat{\boldsymbol{w}}.$$

¿Proyección ortogonal? $\widehat{\boldsymbol{y}} = \widetilde{X}\widehat{\boldsymbol{\theta}}$ es la proyección ortogonal de $\boldsymbol{y}$ sobre $\mathrm{Col}(\widetilde{X})$ si y solo si:

1. $\widehat{\boldsymbol{y}} \in \mathrm{Col}(\widetilde{X})$: se cumple siempre, pues $\widetilde{X}\widehat{\boldsymbol{\theta}}$ es combinación lineal de las columnas de $\widetilde{X}$.
2. $\boldsymbol{r} \perp \mathrm{Col}(\widetilde{X})$, es decir, $\widetilde{X}^\top \boldsymbol{r} = \mathbf{0}$.

En OLS ambas se cumplen. En Ridge, como $\lambda_2 > 0$,

$$\widetilde{X}^\top \boldsymbol{r} = \mathbf{0} \iff \lambda_2 \begin{pmatrix} 0 \\ \widehat{\boldsymbol{w}} \end{pmatrix} = \mathbf{0} \iff \widehat{\boldsymbol{w}} = \mathbf{0},$$

lo cual en general no ocurre: Ridge encoge los pesos, pero solo los anula en el límite $\lambda_2 \to \infty$. Por tanto $X^\top \boldsymbol{r} = \lambda_2 \widehat{\boldsymbol{w}} \neq \mathbf{0}$, la condición 2 falla y el ajuste de Ridge **no** es la proyección ortogonal de $\boldsymbol{y}$ sobre $\mathrm{Col}(\widetilde{X})$. Lo que sí se conserva es $\mathbf{1}_N^\top \boldsymbol{r} = 0$, porque b no se penaliza.

c) Sesgo y varianza de Ridge

Con $b = 0$, derivar $\mathbb{E}[\hat{\mathbf{w}}_{\lambda_2} \mid X]$ y $\mathrm{Cov}(\hat{\mathbf{w}}_{\lambda_2} \mid X)$, expresarlos en las direcciones propias de $X^\top X$ y analizar $\lambda_2 \to 0$ y $\lambda_2 \to \infty$.

Parte 1: esperanza y covarianza.

Paso 1: el estimador. Con $b = 0$ la matriz de penalización es I_D y las ecuaciones normales son $(X^\top X + \lambda_2 I)\widehat{\boldsymbol{w}}_{\lambda_2} = X^\top \boldsymbol{y}$. Como $X^\top X \succ 0$ (rango completo) y $\lambda_2 > 0$, la matriz $X^\top X + \lambda_2 I$ es invertible, y

$$\widehat{\boldsymbol{w}}_{\lambda_2} = (X^\top X + \lambda_2 I)^{-1} X^\top \boldsymbol{y} = A\boldsymbol{y}, \qquad A = (X^\top X + \lambda_2 I)^{-1} X^\top.$$

A es fija, pues X es fija. Condicionado a X, la única fuente de aleatoriedad es $\boldsymbol{\varepsilon}$, luego

$$\mathbb{E}[\boldsymbol{y} \mid X] = X\boldsymbol{w}^\star, \qquad \mathrm{Cov}(\boldsymbol{y} \mid X) = \sigma^2 I_N.$$

Paso 2: esperanza y sesgo. Por linealidad,

$$\mathbb{E}[\widehat{\boldsymbol{w}}_{\lambda_2} \mid X] = A\,\mathbb{E}[\boldsymbol{y} \mid X] = (X^\top X + \lambda_2 I)^{-1} X^\top X\, \boldsymbol{w}^\star.$$

Como $X^\top X = (X^\top X + \lambda_2 I) - \lambda_2 I$,

$$(X^\top X + \lambda_2 I)^{-1} X^\top X = I - \lambda_2 (X^\top X + \lambda_2 I)^{-1},$$

y por tanto

$$\mathrm{Sesgo}(\widehat{\boldsymbol{w}}_{\lambda_2}) = \mathbb{E}[\widehat{\boldsymbol{w}}_{\lambda_2} \mid X] - \boldsymbol{w}^\star = -\lambda_2 (X^\top X + \lambda_2 I)^{-1} \boldsymbol{w}^\star.$$

Con $\lambda_2 = 0$ el sesgo es $\mathbf{0}$: OLS es insesgado.

Paso 3: covarianza. Como $\mathrm{Cov}(A\boldsymbol{y} \mid X) = A\,\mathrm{Cov}(\boldsymbol{y} \mid X)A^\top$,

$$\mathrm{Cov}(\widehat{\boldsymbol{w}}_{\lambda_2} \mid X) = \sigma^2 AA^\top = \sigma^2 (X^\top X + \lambda_2 I)^{-1} X^\top X (X^\top X + \lambda_2 I)^{-1}.$$

Parte 2: direcciones propias de $X^\top X$.

Como $X^\top X$ es simétrica, $X^\top X = V D V^\top$ con $V = [\boldsymbol{v}_1 \ \cdots \ \boldsymbol{v}_D]$ ortogonal y $D = \mathrm{diag}(d_1, \ldots, d_D)$. Por el rango completo, $d_j > 0$ para todo j. Sea $\alpha_j = \boldsymbol{v}_j^\top \boldsymbol{w}^\star$ la componente de $\boldsymbol{w}^\star$ en la dirección $\boldsymbol{v}_j$. Entonces $(X^\top X + \lambda_2 I)^{-1} = V(D + \lambda_2 I)^{-1} V^\top$, y todo se diagonaliza:

$$\boldsymbol{v}_j^\top \mathbb{E}[\widehat{\boldsymbol{w}}_{\lambda_2} \mid X] = \frac{d_j}{d_j + \lambda_2}\,\alpha_j, \qquad \boldsymbol{v}_j^\top \,\mathrm{Sesgo} = -\frac{\lambda_2}{d_j + \lambda_2}\,\alpha_j,$$

$$\mathrm{Cov}(\widehat{\boldsymbol{w}}_{\lambda_2} \mid X) = \sigma^2 V\, D(D + \lambda_2 I)^{-2}\, V^\top, \qquad \mathrm{Var}(\boldsymbol{v}_j^\top \widehat{\boldsymbol{w}}_{\lambda_2} \mid X) = \frac{\sigma^2 d_j}{(d_j + \lambda_2)^2}.$$

Cada dirección se encoge por el factor $d_j/(d_j + \lambda_2) \in (0, 1)$, y se encogen más las direcciones con d_j pequeño.

Parte 3: límites.

Caso $\lambda_2 \to 0$. El sesgo en cada dirección tiende a 0 y la varianza tiende a σ^2/d_j, es decir, Cov $\to \sigma^2 (X^\top X)^{-1}$. Es OLS, y la varianza se vuelve muy grande si algún d_j es pequeño.

Caso $\lambda_2 \to \infty$. La varianza en cada dirección es del orden de $\sigma^2 d_j/\lambda_2^2 \to 0$, pero el sesgo tiende a $-\alpha_j$, es decir, $\widehat{\boldsymbol{w}}_{\lambda_2} \to \mathbf{0}$ y el sesgo total tiende a $-\boldsymbol{w}^\star$.

Parte 4: menor varianza no garantiza menor error cuadrático.

Paso 1: descomposición del error. Sea $\bar{\boldsymbol{w}} = \mathbb{E}[\widehat{\boldsymbol{w}}_{\lambda_2} \mid X]$. Sumando y restando $\bar{\boldsymbol{w}}$,

$$\mathbb{E}\|\widehat{\boldsymbol{w}}_{\lambda_2} - \boldsymbol{w}^\star\|^2 = \|\bar{\boldsymbol{w}} - \boldsymbol{w}^\star\|^2 + \mathbb{E}\|\widehat{\boldsymbol{w}}_{\lambda_2} - \bar{\boldsymbol{w}}\|^2 + 2\,(\bar{\boldsymbol{w}} - \boldsymbol{w}^\star)^\top \mathbb{E}[\widehat{\boldsymbol{w}}_{\lambda_2} - \bar{\boldsymbol{w}}].$$

El último término es 0 porque $\mathbb{E}[\widehat{\boldsymbol{w}}_{\lambda_2} - \bar{\boldsymbol{w}}] = \mathbf{0}$, y $\mathbb{E}\|\widehat{\boldsymbol{w}}_{\lambda_2} - \bar{\boldsymbol{w}}\|^2 = \operatorname{tr}\operatorname{Cov}$. Luego

$$\mathrm{ECM}(\lambda_2) = \|\operatorname{Sesgo}\|^2 + \operatorname{tr}\operatorname{Cov} = \sum_{j=1}^{D} \frac{\lambda_2^2 \alpha_j^2 + \sigma^2 d_j}{(d_j + \lambda_2)^2}.$$

Paso 2: comportamiento en λ_2. Cada sumando $f_j(\lambda_2)$ cumple

$$f_j'(\lambda_2) = \frac{2d_j(\lambda_2 \alpha_j^2 - \sigma^2)}{(d_j + \lambda_2)^3}.$$

- En $\lambda_2 = 0$: $f_j'(0) = -2\sigma^2/d_j^2 < 0$. El sesgo al cuadrado crece como λ_2^2 (muy lento) y la varianza baja linealmente, así que existe $\lambda_2 > 0$ con menor error que OLS.
- Para λ_2 grande: la varianza ya casi no baja, pero el sesgo al cuadrado sube y ECM $\to \|\boldsymbol{w}^\star\|^2$, que puede ser mayor que el error de OLS, $\sigma^2 \sum_j 1/d_j$ (por ejemplo, si $\boldsymbol{w}^\star$ es grande o el ruido es pequeño).
- Cada f_j tiene su mínimo en $\lambda_2 = \sigma^2/\alpha_j^2$, que depende del $\boldsymbol{w}^\star$ desconocido.

Conclusión. Reducir la varianza solo ayuda mientras lo que se gana en varianza supere lo que se pierde en sesgo al cuadrado. Ridge controla las direcciones con d_j pequeño, donde la varianza de OLS es σ^2/d_j, a costa de un sesgo de encogimiento. Un λ_2 demasiado grande empeora el error total. Aquí $b = 0$ está fijo, así que el sesgo es únicamente el de encogimiento y no tiene relación con el intercepto.

1.2. Problema 2. Lasso, esparsidad y representación

a) Caso ortogonal y umbral suave

Con datos centrados, $b = 0$ y $X^\top X/N = I_D$, definir $s = X^\top \mathbf{y}/N$, separar el objetivo en problemas escalares y obtener la regla de umbral suave usando $\partial|0| = [-1, 1]$.

Planteamiento. Como los datos están centrados ($\bar{\mathbf{x}} = \mathbf{0}$, $\bar{y} = 0$), al derivar J_{reg} respecto a b e igualar a cero se obtiene $\hat{b} = \bar{y} - \bar{\mathbf{x}}^\top \mathbf{w} = 0$ para todo $\mathbf{w}$; por tanto, imponer $b = 0$ no altera el

minimizador en $\mathbf{w}$. Lasso corresponde a la convención (4) con la pérdida (2) y $\lambda_2 = 0$, de modo que, usando $z = X\mathbf{w}$,

$$F(\mathbf{w}) = \frac{1}{2N} \|X\mathbf{w} - \mathbf{y}\|_2^2 + \lambda_1 \|\mathbf{w}\|_1 , \qquad \lambda_1 \geq 0. \tag{4}$$

Separación en problemas escalares. Al expandir la norma, y dado que $\mathbf{y}^\top X\mathbf{w}$ es un escalar igual a su transpuesta,

$$\|X\mathbf{w} - \mathbf{y}\|_2^2 = \mathbf{w}^\top X^\top X\mathbf{w} - 2\,\mathbf{w}^\top X^\top \mathbf{y} + \mathbf{y}^\top \mathbf{y}. \tag{5}$$

Por hipótesis, $X^\top X = NI_D$ y $X^\top \mathbf{y} = N\mathbf{s}$. Sustituyendo y dividiendo entre $2N$,

$$F(\mathbf{w}) = \frac{1}{2}\,\mathbf{w}^\top \mathbf{w} - \mathbf{w}^\top \mathbf{s} + \frac{\mathbf{y}^\top \mathbf{y}}{2N} + \lambda_1 \|\mathbf{w}\|_1 = \sum_{j=1}^{D} g_j(w_j) + C, \tag{6}$$

donde

$$g_j(w_j) = \frac{1}{2} w_j^2 - s_j w_j + \lambda_1 |w_j|, \qquad C = \frac{\mathbf{y}^\top \mathbf{y}}{2N}. \tag{7}$$

Como cada g_j depende únicamente de w_j y C no depende de $\mathbf{w}$, minimizar F equivale a minimizar cada g_j por separado. Todas las g_j tienen la misma forma y solo difieren en el índice j; por ello basta resolver el problema genérico

$$g(w) = \frac{1}{2} w^2 - s\,w + \lambda_1 |w|, \qquad s \in \mathbb{R}, \tag{8}$$

y reemplazar después s por s_j.

Convexidad y condición de optimalidad. Una función $g : \mathbb{R} \to \mathbb{R}$ es convexa si para todo $a, b \in \mathbb{R}$ y todo $t \in [0, 1]$

$$g\big(ta + (1-t)b\big) \leq t\,g(a) + (1-t)\,g(b), \tag{9}$$

es decir, si el segmento que une dos puntos de su gráfica nunca queda por debajo de ella. Se descompone $g = g_1 + g_2$, con $g_1(w) = \frac{1}{2} w^2 - s\,w$ y $g_2(w) = \lambda_1 |w|$.

g_1 es dos veces derivable con $g_1''(w) = 1 > 0$. Una función de una variable con segunda derivada no negativa es convexa; como en este caso es estrictamente positiva, g_1 es estrictamente convexa.

Sean $a, b \in \mathbb{R}$ y $t \in [0, 1]$. Por la desigualdad triangular, y como $t \geq 0$ y $1 - t \geq 0$,

$$|ta + (1-t)b| \leq |ta| + |(1-t)b| = t|a| + (1-t)|b|, \tag{10}$$

que es la definición de convexidad para $|\cdot|$. Al multiplicar por $\lambda_1 \geq 0$ la desigualdad se conserva, de modo que g_2 es convexa.

Luego $g = g_1 + g_2$ es también convexa, por propiedad de suma de convexas. Además, es estrictamente convexa, porque g_1 lo es, lo que garantiza que su minimizador, si existe, sea único. Para

una función convexa,

$$w^\star \in \arg\min_w g(w) \iff 0 \in \partial g(w^\star), \tag{11}$$

y en los puntos donde g es derivable esta condición se reduce a $g'(w^\star) = 0$. Se analizan las tres regiones por separado:

Caso $w > 0$. Aquí $|w| = w$, de modo que $g'(w) = w - s + \lambda_1$. Al igualar a cero se obtiene $w = s - \lambda_1$, que pertenece a la región supuesta si y solo si $s - \lambda_1 > 0$. Así,

$$s > \lambda_1 \implies \hat{w} = s - \lambda_1.$$

Caso $w < 0$. Aquí $|w| = -w$, de modo que $g'(w) = w - s - \lambda_1$, cuyo cero es $w = s + \lambda_1$. Este valor es negativo si y solo si $s < -\lambda_1$. Así,

$$s < -\lambda_1 \implies \hat{w} = s + \lambda_1.$$

Caso $w = 0$. En $w = 0$, $|w|$ no es diferenciable, así que no se iguala ninguna derivada a cero: se determina para qué valores de s el punto 0 es el minimizador. La parte $\frac{1}{2}w^2 - s\,w$ es diferenciable, con derivada $-s$ en $w = 0$, y $\partial(\lambda_1|w|)(0) = \lambda_1[-1, 1]$. Por tanto,

$$\partial g(0) = -s + [-\lambda_1, \lambda_1] = [-s - \lambda_1,\ -s + \lambda_1]. \tag{12}$$

La condición $0 \in \partial g(0)$ equivale a $-s - \lambda_1 \leq 0$ y $-s + \lambda_1 \geq 0$, es decir,

$$-\lambda_1 \leq s \leq \lambda_1 \iff |s| \leq \lambda_1 \implies \hat{w} = 0.$$

Los extremos del intervalo $\partial g(0)$ son las pendientes laterales de g en 0: la condición exige que g no decrezca hacia ninguno de los dos lados.

Regla de umbral suave. Las condiciones $s > \lambda_1$, $|s| \leq \lambda_1$ y $s < -\lambda_1$ son mutuamente excluyentes y cubren $\mathbb{R}$, de modo que la regla está definida para todo s:

$$\hat{w} = \begin{cases} s - \lambda_1, & s > \lambda_1, \\ 0, & |s| \leq \lambda_1, \\ s + \lambda_1, & s < -\lambda_1. \end{cases} \tag{13}$$

Proposición 1 (Umbral suave)**.** *Bajo datos centrados, $b = 0$ y $X^\top X/N = I_D$, el minimizador del objetivo Lasso es único y está dado coordenada a coordenada por*

$$\hat{w}_j = S_{\lambda_1}(s_j) = \operatorname{sign}(s_j)\ \text{máx}\,\big(|s_j| - \lambda_1,\, 0\big), \qquad j = 1, \ldots, D. \tag{14}$$

La unicidad se sigue de que cada g_j es estrictamente convexa, ya que contiene el término $\frac{1}{2}w_j^2$.

b) Condiciones de optimalidad y columnas duplicadas

Condiciones de optimalidad coordenada a coordenada en términos de residuos. Con dos columnas iguales y $w_1 + w_2 = s \neq 0$, comparar minimizadores de $w_1^2 + w_2^2$ y $|w_1| + |w_2|$.

Planteamiento. Se mantienen los datos centrados y $b = 0$, pero se elimina la hipótesis $X^\top X/N = I_D$. El objetivo es

$$F(\mathbf{w}) = \underbrace{\frac{1}{2N} \|X\mathbf{w} - \mathbf{y}\|_2^2}_{f(\mathbf{w})} + \underbrace{\lambda_1 \|\mathbf{w}\|_1}_{h(\mathbf{w})}. \tag{15}$$

Sin ortogonalidad, $X^\top X$ tiene términos fuera de la diagonal y el problema ya no se separa por coordenadas, de modo que no se obtiene una fórmula cerrada para $\hat{\mathbf{w}}$. En su lugar se caracteriza el óptimo mediante condiciones que debe cumplir cada coordenada.

Convexidad de F. El gradiente y el Hessiano de la parte suave son

$$\nabla f(\mathbf{w}) = \frac{1}{N} X^\top (X\mathbf{w} - \mathbf{y}), \qquad \nabla^2 f(\mathbf{w}) = \frac{1}{N} X^\top X \in \mathbb{R}^{D \times D}. \tag{16}$$

Para todo $\mathbf{v} \in \mathbb{R}^D$, $\mathbf{v}^\top \nabla^2 f\, \mathbf{v} = \frac{1}{N} \|X\mathbf{v}\|_2^2 \geq 0$, así que el Hessiano es semidefinido positivo y f es convexa sin hipótesis sobre X. Además, h es convexa por la desigualdad triangular y $\lambda_1 \geq 0$. Por tanto, F es convexa y

$$\hat{\mathbf{w}} \in \arg\min_{\mathbf{w}} F(\mathbf{w}) \iff \mathbf{0} \in \partial F(\hat{\mathbf{w}}). \tag{17}$$

A diferencia del caso ortogonal, la curvatura de f en la dirección $\mathbf{v}$ vale $\frac{1}{N} \|X\mathbf{v}\|_2^2$, que es nula si $X\mathbf{v} = \mathbf{0}$ con $\mathbf{v} \neq \mathbf{0}$ (columnas linealmente dependientes). En ese caso F no es necesariamente estrictamente convexa y puede haber varios minimizadores.

Condiciones de optimalidad coordenada a coordenada. Como f es diferenciable, $\partial F(\mathbf{w}) = \nabla f(\mathbf{w}) + \lambda_1\, \partial \|\mathbf{w}\|_1$, y $\partial \|\mathbf{w}\|_1$ está formado por los vectores $\mathbf{u}$ con $u_j \in \partial |w_j|$ para cada j, donde $\partial |w_j| = \{\text{sign}(w_j)\}$ si $w_j \neq 0$ y $\partial |w_j| = [-1, 1]$ si $w_j = 0$. Definiendo el residuo $\hat{\mathbf{r}} = \mathbf{y} - X\hat{\mathbf{w}}$, se tiene $\nabla f(\hat{\mathbf{w}}) = -\frac{1}{N} X^\top \hat{\mathbf{r}}$, cuya componente j es $-\frac{1}{N} \mathbf{x}_j^\top \hat{\mathbf{r}}$, con $\mathbf{x}_j$ la j-ésima columna de X. La condición vectorial $\mathbf{0} \in \partial F(\hat{\mathbf{w}})$ equivale a pedir, para cada $j = 1, \ldots, D$,

$$\frac{1}{N} \mathbf{x}_j^\top \hat{\mathbf{r}} \in \lambda_1\, \partial |\hat{w}_j|, \tag{18}$$

es decir,

$$\begin{cases} \dfrac{1}{N} \mathbf{x}_j^\top \hat{\mathbf{r}} = \lambda_1\ \text{sign}(\hat{w}_j), & \hat{w}_j \neq 0, \\ \left| \dfrac{1}{N} \mathbf{x}_j^\top \hat{\mathbf{r}} \right| \leq \lambda_1, & \hat{w}_j = 0. \end{cases} \tag{19}$$

Aunque se escriben por coordenadas, las condiciones están acopladas, porque $\hat{\mathbf{r}}$ depende de todos los coeficientes.

Columnas duplicadas. Supóngase $\mathbf{x}_1 = \mathbf{x}_2$. Se denota $c = w_1 + w_2 \neq 0$ a la contribución conjunta requerida. Las predicciones dependen de (w_1, w_2) solo a través de su suma:

$$X\mathbf{w} = \mathbf{x}_1(w_1 + w_2) + \sum_{j \geq 3} \mathbf{x}_j w_j. \tag{20}$$

Por tanto, con $w_3, \ldots, w_D$ fijos, todos los pares con $w_1 + w_2 = c$ producen el mismo residuo y el mismo valor de f, y la elección entre ellos la determina únicamente la penalización. Al sustituir $w_2 = c - w_1$:

Penalización L2. Sea $\varphi(w_1) = w_1^2 + (c - w_1)^2 = 2w_1^2 - 2c\,w_1 + c^2$. Como $\varphi'' = 4 > 0$, φ es estrictamente convexa, y $\varphi'(w_1) = 4w_1 - 2c = 0$ da

$$(w_1, w_2) = \left(\tfrac{c}{2}, \tfrac{c}{2}\right), \tag{21}$$

que es el único minimizador. La penalización L2 reparte la contribución por igual.

Penalización L1. Por la desigualdad triangular, $|c| = |w_1 + w_2| \leq |w_1| + |w_2|$, con igualdad si y solo si w_1 y w_2 no tienen signos opuestos. Para $c > 0$, por regiones,

$$\psi(w_1) = |w_1| + |c - w_1| = \begin{cases} c - 2w_1 > c, & w_1 < 0, \\ c, & 0 \leq w_1 \leq c, \\ 2w_1 - c > c, & w_1 > c, \end{cases} \tag{22}$$

y el caso $c < 0$ es simétrico. El conjunto de minimizadores es el segmento

$$\{(t\,c,\ (1-t)\,c) :\ t \in [0,1]\}, \tag{23}$$

que contiene infinitos puntos. La penalización L1 es indiferente al reparto.

	$w_1^2 + w_2^2$	$\lvert w_1\rvert + \lvert w_2\rvert$
Minimizadores	único: $(c/2,\ c/2)$	segmento entre $(c, 0)$ y $(0, c)$
Convexidad	estricta	no estricta
Reparto	iguala	indiferente

Tabla 1: Reparto de la contribución c entre dos columnas idénticas.

Unicidad y estabilidad de la selección.

- **Unicidad.** Con columnas duplicadas, la solución de Lasso no es única, tiene un conjunto de minimizadores como mostrado anteriormente. Por otro lado Ridge sí tiene solución única en $(w_1, w_2) = (c/2, c/2)$.
- **Estabilidad.** Como existen infinitos minimizadores con las mismas predicciones, el que se reporta depende del algoritmo, del punto inicial o del orden de actualización, y no de los datos.

Dos ajustes igualmente óptimos pueden dar $(c, 0)$ y $(0, c)$ y sugerir conclusiones opuestas sobre qué variable es relevante. El patrón de ceros de Lasso no debe interpretarse como evidencia de relevancia individual, y comparar coeficientes uno a uno no basta para verificar una solución.

- **¿Elimina necesariamente una columna?** No. Solo los extremos del segmento ($t = 0$ o $t = 1$) anulan un coeficiente. Por ejemplo, con $c = 4$, el par $(1, 3)$ tiene penalización $|1|+|3| = 4$, igual a la de $(4, 0)$, y el mismo ajuste, de modo que también es un minimizador y conserva ambas columnas.

c) Escalado de una característica

Con $x'_j = ax_j$, $a > 0$: coeficiente equivalente, cambio en las penalizaciones L1 y L2, y por qué el escalador debe estimarse dentro de cada partición de entrenamiento.

Coeficiente equivalente. Se reemplaza solo la característica j por $\mathbf{x}'_j = a\,\mathbf{x}_j$, con $a > 0$, y se mantienen las demás columnas, sus coeficientes y el intercepto. La predicción de la observación n es $\hat{y}_n = b + \sum_k w_k x_{nk}$; como los términos con $k \neq j$ no cambian, las predicciones se conservan si y solo si el término de la variable j es el mismo antes y después:

$$w'_j\, x'_{nj} = w_j\, x_{nj} \iff w'_j\,(a\, x_{nj}) = w_j\, x_{nj} \qquad \text{para todo } n. \tag{24}$$

Basta tomar

$$w'_j = \frac{w_j}{a}, \tag{25}$$

que no depende de n, de modo que un mismo coeficiente conserva todas las predicciones.

Efecto en las penalizaciones. Como $a > 0$, $|a| = a$, y las contribuciones del coeficiente j cambian así:

$$\lambda_1 |w'_j| = \lambda_1 \left|\frac{w_j}{a}\right| = \frac{1}{a}\,\lambda_1 |w_j|, \tag{26}$$

$$\frac{\lambda_2}{2}(w'_j)^2 = \frac{\lambda_2}{2}\,\frac{w_j^2}{a^2} = \frac{1}{a^2}\cdot\frac{\lambda_2}{2} w_j^2. \tag{27}$$

La contribución a L1 se multiplica por $1/a$ y la contribución a L2, por $1/a^2$.

Por qué las unidades afectan la regularización. El término de ajuste J es invariante al cambio de escala, porque las predicciones no cambian, pero la penalización no lo es. Por tanto, el minimizador de F depende de las unidades: una misma variable, con la misma relación con y, se penaliza más o menos según la unidad en que se mida. Si $a > 1$, los valores crecen, el coeficiente equivalente es menor y su penalización baja, de modo que la variable se encoge menos. Si $a < 1$, ocurre lo contrario, y en Lasso la variable tiende a anularse.

Estimación del escalador dentro de cada partición de entrenamiento. La estandarización aplica

$$x'_{nj} = \frac{x_{nj} - \hat{\mu}_j}{\hat{\sigma}_j}, \tag{28}$$

que es una reescala con $a = 1/\hat{\sigma}_j$ más un desplazamiento. El desplazamiento solo modifica el intercepto, que no se penaliza, pero $\hat{\sigma}_j$ fija la penalización efectiva y, con ella, los coeficientes. Como $\hat{\mu}_j$ y $\hat{\sigma}_j$ se estiman con datos, si se calculan usando validación o prueba, la información de esos conjuntos llega al modelo por la cadena

$$\text{datos evaluados} \;\to\; \hat{\sigma}_j \;\to\; \text{penalización} \;\to\; \hat{\mathbf{w}} \;\to\; \text{error medido},$$

lo que constituye una fuga de información. Por ello, el escalador se ajusta solo con el entrenamiento de cada partición, y de cada pliegue en validación cruzada, y luego se aplica sin reajustar a los datos evaluados.

Diferencia con una conversión de unidades fija. Ambas operaciones son reescalas y, por tanto, ambas modifican la penalización y el modelo regularizado. La diferencia está en el origen de sus parámetros: una conversión fija se define sin consultar los datos, así que puede aplicarse a toda la base antes de partir sin riesgo de fuga; la estandarización estima sus parámetros con los datos y, por ello, debe ajustarse dentro de cada partición de entrenamiento.

1.3. Problema 3. Probabilidades, ponderación y decisiones

a) Verosimilitud Bernoulli, gradientes, Hessiano y estabilidad

Derivar (3) a partir de una verosimilitud Bernoulli, sus gradientes respecto a $\mathbf{w}$ *y* b *y su Hessiano en* $\boldsymbol{\theta}$*. Justificar la convexidad y las hipótesis para convexidad estricta. Explicar por qué no existe minimizador finito con clases perfectamente separables. Expresar la pérdida con* $\log(1 + e^z)$ *y proponer una evaluación estable.*

Modelo y verosimilitud. Para cada observación $i = 1, \ldots, N$, con $\mathbf{x}_i \in \mathbb{R}^D$ la fila i de X escrita como columna, se supone

$$Y_i \mid \mathbf{x}_i \sim \text{Bernoulli}(p_i), \qquad p_i = \sigma(z_i), \qquad z_i = \mathbf{w}^\top \mathbf{x}_i + b, \tag{29}$$

donde Y_i, z_i y p_i son escalares. El modelo supone que las log-odds son lineales, $\log \frac{p_i}{1-p_i} = z_i$, y la sigmoide traduce el puntaje $z_i \in \mathbb{R}$ a una probabilidad en $(0, 1)$. La función de masa de una Bernoulli puede escribirse como $P(Y_i = y_i \mid \mathbf{x}_i) = p_i^{y_i}(1 - p_i)^{1-y_i}$, que vale p_i si $y_i = 1$ y $1 - p_i$ si $y_i = 0$. Bajo independencia condicional,

$$L(\mathbf{w}, b) = \prod_{i=1}^{N} p_i^{y_i}(1 - p_i)^{1-y_i}, \qquad \ell(\mathbf{w}, b) = \log L = \sum_{i=1}^{N} \big[y_i \log p_i + (1 - y_i) \log(1 - p_i)\big]. \tag{30}$$

Como el logaritmo es creciente, maximizar L equivale a maximizar ℓ, que a su vez equivale a minimizar $-\ell$. Dividir entre $N > 0$ no cambia el minimizador y convierte la suma en un promedio, de modo que

$$J_{\log}(\mathbf{w}, b) = -\frac{\ell(\mathbf{w}, b)}{N} = -\frac{1}{N}\sum_{i=1}^{N}\left[y_i \log p_i + (1 - y_i)\log(1 - p_i)\right], \tag{31}$$

que es la ecuación (3). Minimizar la pérdida logística es, por tanto, estimar por máxima verosimilitud.

Gradientes. Sea $\ell_i = -\left[y_i \log p_i + (1-y_i)\log(1-p_i)\right]$, de modo que $J_{\log} = \frac{1}{N}\sum_i \ell_i$. Los parámetros afectan a ℓ_i a través de la cadena $(\mathbf{w}, b) \to z_i \to p_i \to \ell_i$, por lo que

$$\frac{\partial \ell_i}{\partial \mathbf{w}} = \frac{\partial \ell_i}{\partial p_i} \cdot \frac{dp_i}{dz_i} \cdot \frac{\partial z_i}{\partial \mathbf{w}}, \qquad \frac{\partial \ell_i}{\partial b} = \frac{\partial \ell_i}{\partial p_i} \cdot \frac{dp_i}{dz_i} \cdot \frac{\partial z_i}{\partial b}. \tag{32}$$

Se calcula cada eslabón.

Eslabón 1. Derivando ℓ_i respecto a p_i,

$$\frac{\partial \ell_i}{\partial p_i} = -\frac{y_i}{p_i} + \frac{1 - y_i}{1 - p_i}. \tag{33}$$

Eslabón 2. Con $\sigma(z) = (1 + e^{-z})^{-1}$,

$$\sigma'(z) = \frac{e^{-z}}{(1 + e^{-z})^2} = \frac{1}{1 + e^{-z}} \cdot \frac{e^{-z}}{1 + e^{-z}} = \sigma(z)(1 - \sigma(z)), \tag{34}$$

ya que $1 - \frac{1}{1+e^{-z}} = \frac{e^{-z}}{1+e^{-z}}$. Por tanto, $\frac{dp_i}{dz_i} = p_i(1 - p_i)$.

Eslabones 1 y 2 juntos.

$$\frac{\partial \ell_i}{\partial z_i} = \frac{\partial \ell_i}{\partial p_i} \cdot \frac{dp_i}{dz_i} = \left(-\frac{y_i}{p_i} + \frac{1 - y_i}{1 - p_i}\right) p_i(1 - p_i) = -y_i(1 - p_i) + (1 - y_i)p_i = p_i - y_i. \tag{35}$$

Eslabón 3. Como $z_i = \mathbf{w}^\top \mathbf{x}_i + b$, se tiene $\frac{\partial z_i}{\partial \mathbf{w}} = \mathbf{x}_i \in \mathbb{R}^D$ y $\frac{\partial z_i}{\partial b} = 1$.

Resultado. Sustituyendo en la regla de la cadena y promediando,

$$\nabla_{\mathbf{w}} J_{\log} = \frac{1}{N}\sum_{i=1}^{N}(p_i - y_i)\,\mathbf{x}_i = \frac{1}{N} X^\top(\mathbf{p} - \mathbf{y}) \in \mathbb{R}^D, \tag{36}$$

$$\frac{\partial J_{\log}}{\partial b} = \frac{1}{N}\sum_{i=1}^{N}(p_i - y_i) = \frac{1}{N}\mathbf{1}_N^\top(\mathbf{p} - \mathbf{y}) \in \mathbb{R}, \tag{37}$$

con $\mathbf{p} = (p_1, \ldots, p_N)^\top$. La forma matricial usa que $X^\top \mathbf{v} = \sum_i v_i \mathbf{x}_i$. En la parametrización aumentada, con $\tilde{\mathbf{x}}_i = (1, \mathbf{x}_i^\top)^\top$, $\boldsymbol{\theta} = (b, \mathbf{w}^\top)^\top$ y $z_i = \boldsymbol{\theta}^\top \tilde{\mathbf{x}}_i$,

$$\nabla_{\boldsymbol{\theta}} J_{\log} = \frac{1}{N}\sum_{i=1}^{N}(p_i - y_i)\,\tilde{\mathbf{x}}_i = \frac{1}{N}\tilde{X}^\top(\mathbf{p} - \mathbf{y}) \in \mathbb{R}^{D+1}. \tag{38}$$

Tiene la misma forma que el gradiente de mínimos cuadrados, con $\mathbf{p}$ en lugar de $\mathbf{z}$, pero $\mathbf{p}$ depende de $\boldsymbol{\theta}$ de forma no lineal y no hay solución en forma cerrada.

Hessiano. En cada término $(p_i - y_i)\,\tilde{\mathbf{x}}_i$ del gradiente, y_i y $\tilde{\mathbf{x}}_i$ son datos y solo p_i depende de $\boldsymbol{\theta}$. Por la regla de la cadena,

$$\frac{\partial p_i}{\partial \boldsymbol{\theta}} = \frac{dp_i}{dz_i} \cdot \frac{\partial z_i}{\partial \boldsymbol{\theta}} = p_i(1-p_i)\,\tilde{\mathbf{x}}_i, \tag{39}$$

y, como el término es el vector fijo $\tilde{\mathbf{x}}_i$ multiplicado por un escalar,

$$\frac{\partial}{\partial \boldsymbol{\theta}^\top}\left[(p_i - y_i)\,\tilde{\mathbf{x}}_i\right] = \tilde{\mathbf{x}}_i \left(\frac{\partial p_i}{\partial \boldsymbol{\theta}}\right)^\top = p_i(1-p_i)\,\tilde{\mathbf{x}}_i\tilde{\mathbf{x}}_i^\top. \tag{40}$$

Sumando y promediando,

$$H(\boldsymbol{\theta}) = \nabla^2_{\boldsymbol{\theta}} J_{\log} = \frac{1}{N}\sum_{i=1}^{N} p_i(1-p_i)\,\tilde{\mathbf{x}}_i\tilde{\mathbf{x}}_i^\top = \frac{1}{N}\tilde{X}^\top S\,\tilde{X}, \qquad S = \operatorname{diag}\left(p_1(1-p_1), \ldots, p_N(1-p_N)\right), \tag{41}$$

con dimensiones $(D+1)\times N$, $N \times N$ y $N \times (D+1)$, de modo que $H \in \mathbb{R}^{(D+1)\times(D+1)}$. A diferencia de mínimos cuadrados, H depende de $\boldsymbol{\theta}$ a través de los p_i.

Convexidad y convexidad estricta. Para todo $\mathbf{v} \in \mathbb{R}^{D+1}$,

$$\mathbf{v}^\top H \mathbf{v} = \frac{1}{N}\sum_{i=1}^{N} p_i(1-p_i)\,\mathbf{v}^\top\tilde{\mathbf{x}}_i\tilde{\mathbf{x}}_i^\top\mathbf{v} = \frac{1}{N}\sum_{i=1}^{N} p_i(1-p_i)\,(\tilde{\mathbf{x}}_i^\top\mathbf{v})^2 \geq 0, \tag{42}$$

porque $p_i = \sigma(z_i) \in (0,1)$ implica $p_i(1-p_i) > 0$, y los cuadrados son no negativos. Así, H es semidefinido positivo y $J_{\log}$ es convexa para cualesquiera $\tilde{X}$ e $\mathbf{y}$. Como todos los pesos son estrictamente positivos,

$$\mathbf{v}^\top H\mathbf{v} = 0 \iff \tilde{\mathbf{x}}_i^\top\mathbf{v} = 0 \ \ \forall i \iff \tilde{X}\mathbf{v} = \mathbf{0}. \tag{43}$$

Por tanto, H es definido positivo, y $J_{\log}$ estrictamente convexa, si y solo si $\tilde{X} = [\mathbf{1}_N\ X]$ tiene rango columna completo. Esto exige $N \geq D+1$, que ninguna variable sea combinación lineal de otras y que ninguna sea constante, pues sería proporcional a la columna del intercepto. Bajo esa hipótesis, el minimizador es único *si existe*.

Separabilidad perfecta. Las clases son linealmente separables si existe $\boldsymbol{\theta}^\star$ tal que $z_i^\star = \boldsymbol{\theta}^{\star\top}\tilde{\mathbf{x}}_i > 0$ cuando $y_i = 1$ y $z_i^\star < 0$ cuando $y_i = 0$. Para analizar este caso, se escribe la pérdida de cada observación en función de z_i. Si $y_i = 1$, $\ell_i = -\log\sigma(z_i) = \log(1+e^{-z_i})$. Si $y_i = 0$, como $1-\sigma(z) = \frac{e^{-z}}{1+e^{-z}} = \frac{1}{1+e^{z}} = \sigma(-z)$, se tiene $\ell_i = \log(1+e^{z_i})$. Con $t_i = 2y_i - 1 \in \{-1,+1\}$, ambos casos se resumen en

$$\ell_i = \log\left(1 + e^{-t_i z_i}\right), \tag{44}$$

donde $t_i z_i > 0$ indica una observación bien clasificada.

- Como $1 + e^{-t_i z_i} > 1$, se tiene $\ell_i > 0$, y por tanto $J_{\log}(\boldsymbol{\theta}) > 0$ para todo $\boldsymbol{\theta}$ finito.
- Sea $m = \min_i t_i z_i^\star > 0$. Como z_i es lineal en $\boldsymbol{\theta}$, para $c > 0$ se tiene $z_i(c\,\boldsymbol{\theta}^\star) = c\, z_i^\star$, y como e^{-u} es decreciente,

$$0 < J_{\log}(c\,\boldsymbol{\theta}^\star) \leq \log\left(1 + e^{-cm}\right) \xrightarrow[c\to\infty]{} 0. \tag{45}$$

El ínfimo de $J_{\log}$ es 0, pero ningún $\boldsymbol{\theta}$ finito lo alcanza. Si existiera un minimizador $\hat{\boldsymbol{\theta}}$ con $J_{\log}(\hat{\boldsymbol{\theta}}) = \varepsilon > 0$, bastaría tomar c grande para obtener $J_{\log}(c\,\boldsymbol{\theta}^\star) < \varepsilon$, una contradicción. Por tanto, no existe minimizador finito.

La convexidad, incluso estricta, garantiza que todo mínimo local es global y que es único, pero no que exista: por ejemplo, $f(u) = e^{-u}$ es estrictamente convexa y no alcanza su ínfimo 0. Aquí, la curvatura $p_i(1-p_i)$ tiende a 0 cuando $|z_i| \to \infty$ y la pérdida decrece indefinidamente en la dirección de $\boldsymbol{\theta}^\star$.

Expresión con $\log(1 + e^z)$. En el caso $y_i = 1$, sacando e^{-z_i} como factor común,

$$\log(1 + e^{-z_i}) = \log\left(e^{-z_i}(e^{z_i} + 1)\right) = \log(1 + e^{z_i}) - z_i. \tag{46}$$

Como el caso $y_i = 0$ es $\log(1 + e^{z_i})$, y $y_i \in \{0, 1\}$,

$$\ell_i = \log(1 + e^{z_i}) - y_i z_i, \qquad J_{\log} = \frac{1}{N}\sum_{i=1}^{N}\left[\log(1 + e^{z_i}) - y_i z_i\right], \tag{47}$$

que se evalúa directamente desde z_i, sin calcular p_i ni $\log p_i$.

Evaluación estable. En aritmética de doble precisión, e^z desborda para $z \gtrsim 709$, y $1 + \varepsilon$ se redondea a 1 si $\varepsilon \lesssim 10^{-16}$. Por ello, la evaluación ingenua falla: con $z = 40$ e $y = 0$, $\sigma(40)$ se redondea a 1 y $\log(1 - p) = \log 0$; con $z = 1000$, e^{1000} desborda. Sacando como factor común el exponencial mayor, si $z \geq 0$, $\log(1 + e^z) = z + \log(1 + e^{-z})$, y si $z < 0$ se conserva la expresión original. Ambos casos se resumen en la identidad exacta

$$\log(1 + e^z) = \max(z, 0) + \log\left(1 + e^{-|z|}\right), \tag{48}$$

en la que $e^{-|z|} \in (0, 1]$ nunca desborda. El último término se calcula con $\mathrm{log1p}(e^{-|z|})$ para conservar precisión cuando $e^{-|z|}$ es diminuto.

z	y	Evaluación ingenua	$\max(z,0)+\log(1+e^{-\lvert z\rvert})-yz$
1000	0	`inf`	1000
1000	1	`inf`	0
-1000	1	`inf`	1000
-1000	0	0	0

Tabla 2: Pérdida logística para puntajes extremos.

A diferencia de recortar p o z, esta forma no altera el valor de la pérdida. Del mismo modo, la sigmoide se evalúa de forma estable como

$$\sigma(z)=\begin{cases}\dfrac{1}{1+e^{-z}}, & z\geq 0,\\[2ex] \dfrac{e^{z}}{1+e^{z}}, & z<0,\end{cases} \tag{49}$$

de modo que el exponente sea siempre no positivo.

b) Decisión con costos asimétricos

Con $C_{FP}=1$ y $C_{FN}=12$, y $p=P(Y=1\mid\mathbf{x})$ verdadera, derivar la regla que minimiza el costo condicional esperado y su umbral. Calcular ambos costos para $p=0.10$, comparar con $\tau=0.5$ y explicar por qué el umbral no impone una capacidad máxima de alertas.

Planteamiento. Para cada vuelo i con características $\mathbf{x}_i$ se decide $\hat{y}_i\in\{0,1\}$: alertar ($\hat{y}_i=1$) o no alertar ($\hat{y}_i=0$), donde $Y_i=1$ indica retraso. Se supone que $p_i=P(Y_i=1\mid\mathbf{x}_i)$ es la probabilidad verdadera. Los costos son:

	$Y_i=1$ (retraso)	$Y_i=0$ (sin retraso)
$\hat{y}_i=1$ (alertar)	0	$C_{FP}=1$
$\hat{y}_i=0$ (no alertar)	$C_{FN}=12$	0

Tabla 3: Costos de cada combinación de decisión y resultado.

Costo condicional esperado de cada decisión. Al decidir no se conoce Y_i, sino solo $P(Y_i=1\mid\mathbf{x}_i)=p_i$ y $P(Y_i=0\mid\mathbf{x}_i)=1-p_i$. El costo esperado de cada decisión es el promedio de sus costos posibles ponderado por esas probabilidades:

$$\mathbb{E}[\text{costo}\mid\hat{y}_i=1,\mathbf{x}_i]=0\cdot p_i+C_{FP}(1-p_i)=1-p_i, \tag{50}$$

$$\mathbb{E}[\text{costo}\mid\hat{y}_i=0,\mathbf{x}_i]=C_{FN}\,p_i+0\cdot(1-p_i)=12\,p_i. \tag{51}$$

Regla óptima y umbral. Se alerta cuando alertar cuesta, en promedio, lo mismo o menos que no alertar:

$$1 - p_i \leq 12\, p_i \iff 1 \leq 13\, p_i \iff p_i \geq \frac{1}{13}. \tag{52}$$

Con costos genéricos, el mismo razonamiento da $C_{FP}(1 - p_i) \leq C_{FN}\, p_i \iff p_i \geq \frac{C_{FP}}{C_{FP}+C_{FN}}$, de modo que

$$\hat{y}_i = \mathbf{1}\{p_i \geq \tau^\star\}, \qquad \tau^\star = \frac{C_{FP}}{C_{FP} + C_{FN}} = \frac{1}{13} \approx 0.0769. \tag{53}$$

En $p_i = \tau^\star$ ambas decisiones tienen el mismo costo; se alerta por convención. Como el costo esperado total es el promedio de los costos condicionales de todos los vuelos, elegir en cada vuelo la decisión más barata minimiza también el costo total: esta es la regla de decisión de Bayes. Como un retraso no alertado cuesta doce veces más que una alerta innecesaria, conviene alertar aun cuando el retraso es poco probable.

Ejemplo con $p = 0.10$. Alertar tiene costo esperado $1-0.10 = 0.90$, y no alertar, $12\times0.10 = 1.20$. Como $0.10 \geq 1/13$, la regla óptima alerta. En cambio, con $\tau = 0.5$ se tiene $0.10 < 0.5$ y no se alerta.

Umbral	Decisión con $p = 0.10$	Costo esperado
$\tau^\star = 1/13$	Alertar	0.90
$\tau = 0.5$	No alertar	1.20

Tabla 4: Comparación de umbrales para un vuelo con $p = 0.10$.

El umbral 0.5 aumenta el costo esperado de este vuelo en 0.30, es decir, en un tercio. Ese umbral solo es óptimo cuando $C_{FP} = C_{FN}$, pues entonces $\tau^\star = \frac{C}{2C} = 0.5$; con costos asimétricos ignora que los falsos negativos son mucho más caros.

El umbral no impone una capacidad máxima de alertas. $\tau^\star$ es una regla individual: compara la probabilidad de cada vuelo con $1/13$ sin considerar a los demás. La proporción de alertas,

$$\frac{\#\{i :\ p_i \geq \tau^\star\}}{N}, \tag{54}$$

depende de cuántos vuelos tienen probabilidad alta, es decir, de la distribución de los p_i, que el umbral no controla. Por ejemplo, si en una temporada de lluvias el 60 % de los vuelos tiene $p_i \geq 1/13$, la regla alertará el 60 % de los vuelos, aunque solo sea posible atender una fracción menor. Esto ocurre porque el costo se minimizó vuelo por vuelo y cada alerta tiene un costo fijo, independiente de cuántas alertas se emitan en total; nada en la función de costo penaliza el volumen de alertas. Un límite de capacidad, como alertar a lo sumo una fracción κ de los vuelos, es una restricción global que liga las decisiones de todos los vuelos. Imponerlo exige minimizar el costo sujeto a esa restricción, lo que en general obliga a usar un umbral mayor que $\tau^\star$ y a aceptar más retrasos no alertados.

c) Ponderación de clases

Para $R(q) = -a_1 p \log q - a_0(1-p)\log(1-q)$, obtener $q^\star$ en función de p, a_0, a_1, determinar cuándo $q^\star = p$, analizar si es correcto aplicar a $q^\star$ el umbral del inciso b) y distinguir el resultado poblacional de lo que ocurre con muestra finita, modelo restringido y regularización.

Planteamiento. Se fija un vuelo con características $\mathbf{x}$. Se distinguen dos probabilidades: $p = P(Y = 1 \mid \mathbf{x})$ es la probabilidad verdadera de retraso, fija y desconocida, y $q \in (0,1)$ es la probabilidad que predice el modelo para ese vuelo. Con la notación del inciso a), q corresponde a $\sigma(z_i)$. Si se usa la pérdida logística con pesos de clase $a_1 > 0$ para los retrasos y $a_0 > 0$ para los no retrasos, con probabilidad p el vuelo se retrasa y la pérdida es $-a_1 \log q$, y con probabilidad $1-p$ no se retrasa y la pérdida es $-a_0 \log(1-q)$. La pérdida esperada al predecir q es

$$R(q) = -a_1\, p \log q - a_0(1-p)\log(1-q). \tag{55}$$

Con $a_0 = a_1 = 1$, R es la pérdida logística esperada sin ponderar.

Minimizador. Derivando,

$$R'(q) = -\frac{a_1\, p}{q} + \frac{a_0(1-p)}{1-q}. \tag{56}$$

Al igualar a cero y multiplicar en cruz, $a_1\, p\,(1-q) = a_0(1-p)\, q$, es decir, $a_1\, p = q\big[a_1\, p + a_0(1-p)\big]$, de donde

$$q^\star = \frac{a_1\, p}{a_1\, p + a_0(1-p)} \in (0,1). \tag{57}$$

Como

$$R''(q) = \frac{a_1\, p}{q^2} + \frac{a_0(1-p)}{(1-q)^2} > 0 \quad \text{para todo } q \in (0,1), \tag{58}$$

R es estrictamente convexa en $(0,1)$ y $q^\star$ es su único minimizador. Dividiendo $q^\star$ entre $1 - q^\star = \frac{a_0(1-p)}{a_1 p + a_0(1-p)}$,

$$\frac{q^\star}{1-q^\star} = \frac{a_1}{a_0} \cdot \frac{p}{1-p}, \tag{59}$$

es decir, la ponderación multiplica las odds verdaderas por a_1/a_0. Si $a_1 > a_0$, el modelo predice probabilidades de retraso mayores que las verdaderas. Por ejemplo, con $a_1 = 5$, $a_0 = 1$ y $p = 0.10$, se obtiene $q^\star = \frac{0.50}{1.40} \approx 0.357$.

Condición para $q^\star = p$. Igualando $q^\star = p$ y dividiendo entre $p > 0$,

$$a_1 = a_1\, p + a_0(1-p) \iff a_1(1-p) = a_0(1-p) \iff a_1 = a_0, \tag{60}$$

donde la última equivalencia usa $1 - p > 0$. Por tanto, $q^\star = p$ si y solo si ambas clases tienen el mismo peso, lo que incluye el caso sin ponderar: la pérdida logística sin pesos lleva a predecir la probabilidad verdadera. Con $a_1 \neq a_0$, se tiene $q^\star \neq p$ para todo $p \in (0,1)$.

Aplicación del umbral del inciso b). El umbral $\tau^\star = 1/13$ se derivó suponiendo que el puntaje es la probabilidad verdadera p, por lo que no puede aplicarse directamente a $q^\star$ cuando $a_1 \neq a_0$. Como $q^\star$ es una función creciente de p, la regla óptima se conserva si se transforma el umbral:

$$p \geq \tau^\star \iff q^\star \geq \tau_q, \qquad \tau_q = \frac{a_1\,\tau^\star}{a_1\,\tau^\star + a_0(1-\tau^\star)}, \tag{61}$$

o, de forma equivalente, recuperando $p = \frac{a_0\,q^\star}{a_0\,q^\star + a_1(1-q^\star)}$ y comparándolo con $\tau^\star$. Con $a_1 = 5$ y $a_0 = 1$, se obtiene $\tau_q = \frac{5/13}{5/13+12/13} = \frac{5}{17} \approx 0.294$. Para un vuelo con $p = 0.05 < 1/13$, la decisión óptima es no alertar, pero $q^\star = \frac{0.25}{1.20} \approx 0.208$:

Umbral aplicado a $q^\star$	Decisión	¿Coincide con la óptima?
$\tau^\star = 1/13 \approx 0.077$	Alertar	No
$\tau_q = 5/17 \approx 0.294$	No alertar	Sí

Tabla 5: Vuelo con $p = 0.05$, $a_1 = 5$ y $a_0 = 1$.

Aplicar $1/13$ directamente a $q^\star$ con $a_1 > a_0$ produce demasiadas alertas, porque la asimetría se cuenta dos veces: una en los pesos, que ya inflaron las probabilidades, y otra en el umbral.

Resultado poblacional frente a la práctica. El análisis anterior es ideal: supone que se conoce la esperanza verdadera, es decir p, y que el modelo puede asignar cualquier valor q a cada $\mathbf{x}$ por separado. En la práctica:

- **Muestra finita.** Se minimiza un promedio sobre los datos observados, no la esperanza $R(q)$. La estimación $\hat{q}$ tiene error de muestreo, de modo que $\hat{q} \neq q^\star$ aun con un modelo flexible. Con pesos grandes en una clase poco frecuente, pocas observaciones dominan la pérdida y la estimación se vuelve más variable.
- **Modelo restringido.** La regresión logística impone $q(\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b)$ con los mismos parámetros para todos los vuelos, así que el ajuste es un compromiso entre vuelos, y los pesos cambian cuáles se priorizan. Si las log-odds verdaderas son exactamente lineales en $\mathbf{x}$, entonces $\log \frac{q^\star}{1-q^\star} = \log \frac{p}{1-p} + \log \frac{a_1}{a_0}$ sigue siendo lineal y la ponderación solo desplaza el intercepto en $\log(a_1/a_0)$; en ese caso la transformación del umbral es exacta en la población. Si el modelo está mal especificado, los pesos también modifican $\mathbf{w}$, y $\hat{q}$ deja de ser la transformación $q^\star$ de la probabilidad verdadera.
- **Regularización.** La penalización encoge $\mathbf{w}$ hacia cero y acerca las probabilidades predichas a un valor común determinado por el intercepto, que no se penaliza: los vuelos de riesgo alto reciben probabilidades menores y los de riesgo bajo, mayores. Este sesgo se suma a la distorsión de los pesos.

En consecuencia, ni $\hat{q} = q^\star$ ni la corrección τ_q se cumplen exactamente, y el umbral debe elegirse empíricamente, evaluando el costo sobre datos no usados para ajustar el modelo.

2. Parte II. Implementación y experimentación

Los tres notebooks y el módulo común están en el repositorio entregado; aquí solo se resumen las decisiones, los resultados que las respaldan y lo que se concluye de ellos. Todas las comparaciones entre modelos usan las mismas particiones, y el conjunto de prueba solo se usó una vez, al final de cada problema aplicado.

2.1. Problema 4. Modelos desde cero y verificación numérica

Decisiones metodológicas

Cada método es una clase (OLS, Ridge, regresión lineal por gradiente, Lasso proximal y logística) con una base común para validar entradas, predecir, guardar y cargar. El intercepto nunca se penaliza. OLS usa `lstsq`, que devuelve la solución de norma mínima si $\tilde{X}$ no tiene rango completo, y Ridge resuelve sus ecuaciones normales. Los métodos iterativos usan paso $\eta = 1/L$, con L la constante de Lipschitz del gradiente ($\|\tilde{X}\|_2^2/N + \lambda_2$ en regresión y su cuarta parte en logística), y se detienen cuando la norma del gradiente, o el residuo proximal $\|\theta^+ - \theta\|/\eta$ en Lasso, baja de la tolerancia. La sigmoide y la pérdida logística se evalúan de forma estable, sin exponentes positivos ni $\log(0)$.

Resultados esenciales

Prueba	Criterio	Resultado
Gradiente frente a diferencias centrales (regresión y logística, $\lambda_2 \in \{0; 0{,}1\}$, tres puntos)	error relativo $< 10^{-5}$	$\leq 2{,}6 \times 10^{-10}$
Sigmoide y pérdida con $z \in [-1000, 1000]$	finitas, sin avisos de desbordamiento	cumple
OLS con una columna duplicada	rango 5 de 6; $\|\tilde{X}^\top r\|/N \approx 0$	$1{,}2 \times 10^{-14}$
Ridge: ecuaciones normales	residuo ≈ 0	$3{,}9 \times 10^{-16}$
Lasso: condiciones de optimalidad (correlacionada / ortogonal)	violación $< 10^{-6}$	$7{,}6 \times 10^{-13}$ / $8{,}3 \times 10^{-17}$
Lasso ortogonal frente a forma cerrada $S_{\lambda_1}(x_j^\top y/N)$	iguales hasta 10^{-6}	cumple
Guardar y cargar; cambiar τ	predicciones idénticas; τ no cambia probabilidades ni pérdida	cumple

Tabla 6: ¿Están bien implementados los modelos?

Propio	scikit-learn	máx $\lvert\Delta w\rvert$	máx $\lvert\Delta \hat{y}\rvert$	ΔF
OLS	`LinearRegression`	2×10^{-15}	8×10^{-15}	≈ 0
Ridge, λ_2	`Ridge`, $\alpha = N\lambda_2$	9×10^{-16}	2×10^{-15}	≈ 0
Lasso, λ_1	`Lasso`, $\alpha = \lambda_1$	6×10^{-13}	1×10^{-12}	≈ 0
Logística, λ_2	`LogisticRegression`, $C = 1/(N\lambda_2)$	9×10^{-8}	1×10^{-7}	-1×10^{-15}

Tabla 7: ¿Coinciden con scikit-learn bajo la conversión de λ? Máximos sobre $\lambda \in \{10^{-2}, 10^{-1}, 1\}$; ΔF es la diferencia de objetivo con la convención (4).

Las conversiones salen de igualar objetivos: scikit-learn multiplica la pérdida cuadrática de Ridge por N respecto a la convención (4), usa la misma escala en Lasso y en la logística pone C sobre la suma de pérdidas en lugar de λ_2 sobre la penalización.

Conclusiones

- **Todas las pruebas pasaron.** Gradientes, estabilidad numérica, optimalidad y persistencia quedaron verificados; la penalización L_1, que no es diferenciable, se verificó con las condiciones de optimalidad y no con diferencias finitas.
- **Las discrepancias con scikit-learn son numéricas, no de formulación.** Las soluciones cerradas coinciden a precisión de máquina; la logística difiere en 10^{-7}, del orden de la tolerancia del descenso por gradiente, con objetivos iguales a 10^{-15}.
- **La correlación cuesta iteraciones.** Lasso converge en 2 iteraciones con columnas ortogonales y en 2517 con columnas correlacionadas, como se vuelve a ver en el problema 5.

2.2. Problema 5. Simulación de sesgo, varianza y selección

Decisiones metodológicas

Diseño. $N = 120$ filas de entrenamiento, $M = 1000$ de auditoría y $D = 20$ variables en cuatro bloques de cinco, con correlación $\rho \in \{0;\ 0{,}9\}$ dentro de cada bloque y soporte $S^\star = \{1, 6, 11, 16\}$, una variable por bloque. X y X_* quedan fijas y solo cambia el ruido entre las $R = 40$ réplicas; el intercepto es 0 y conocido. Las subsemillas salen de la maestra 2026 con `SeedSequence.spawn`, y los dos escenarios comparten Z, Z_* y $\varepsilon^{(r)}$ en $X = ZL^\top$ ($LL^\top = \Sigma_\rho$). Como $L^\top w^\star = w^\star$, la señal y las respuestas son idénticas en ambos escenarios: solo cambia la matriz de ajuste. La correlación media dentro de los bloques fue $-0{,}03$ y $0{,}90$, y $\mathrm{cond}(X^\top X)$ pasó de 5,3 a 151,6.

Ajustes y métricas. OLS, Ridge y Lasso (ISTA, `tol` $= 10^{-10}$; los 400 ajustes convergieron) con la grilla de λ y solo la penalización de cada método. $\widehat{V}$ usa $1/R$ porque así el término cruzado se anula y $\widehat{E}_f = \widehat{B}^2 + \widehat{V}$ es exacta (error máximo $1{,}8 \times 10^{-15}$). Una variable está seleccionada si $|\hat{w}_j| > 10^{-6}$, umbral fijado antes de ver resultados, y un bloque está recuperado si se selecciona alguna de sus variables.

Resultados esenciales

		$\rho = 0$			$\rho = 0{,}9$		
Modelo	λ	$\widehat{B}^2$	$\widehat{V}$	$\widehat{E}_f$	$\widehat{B}^2$	$\widehat{V}$	$\widehat{E}_f$
OLS	–	0,008	0,202	0,210	0,008	0,202	0,210
Ridge	10^{-2}	0,010	0,196	0,206	0,024	0,162	0,187
Ridge	1	3,954	0,039	3,993	1,551	0,024	1,574
Lasso	10^{-1}	0,033	0,051	**0,083**	0,048	0,060	**0,107**
Lasso	1	3,052	0,030	3,082	3,049	0,032	3,080

Tabla 8: ¿Cómo se reparte el error entre sesgo y varianza? Selección de la tabla del notebook.

Al subir λ, $\widehat{V}$ baja, $\widehat{B}^2$ sube y $\widehat{E}_f$ tiene forma de U; Lasso con $\lambda_1 = 10^{-1}$ reduce a menos de la mitad el error de OLS. OLS da lo mismo en ambos escenarios porque sus predicciones son invariantes a reparametrizaciones lineales de X; Ridge y Lasso no, porque sus penalizaciones sí dependen de las coordenadas. Para una respuesta nueva el error esperado es $E_f + \sigma^2$, y para Ridge $\widehat{V}$ difiere menos de 3 % de su valor teórico.

En selección, con $\rho = 0$ Lasso recupera el soporte exacto en todas las réplicas con $\lambda_1 \in [0{,}32;\ 0{,}75]$, pero ahí $\widehat{E}_f$ vale entre 0,34 y 1,77; el mínimo de $\widehat{E}_f$ (0,083, en $\lambda_1 = 0{,}1$) tiene precisión 0,53 y ningún soporte exacto. Con $\rho = 0{,}9$ el soporte exacto nunca supera el 27,5 %, aunque los cuatro bloques se recuperan siempre que $\lambda_1 \leq 0{,}75$. Hay sustitución solo en el bloque 4 (13 de 40 réplicas con $\lambda_1 = 1$), con el signo de $w^\star_{16}$.

Conclusiones

- **La regularización no reduce a la vez sesgo y varianza.** La baja conjunta con λ pequeño es ruido de Monte Carlo: $\mathbb{E}[\widehat{B}^2] \approx B^2 + V/R$, y el $\widehat{B}^2 = 0{,}008$ de OLS, insesgado, es solo ese término. El sesgo exacto de Ridge crece con λ_2; mejora el error total porque la varianza cae más.
- **Predecir mejor no implica recuperar el soporte.** Eliminar todas las irrelevantes exige un λ que también encoge a las relevantes; las que sobreviven con $\lambda_1 \approx 0{,}1$ cuestan poca varianza.
- **Hay sustitución con correlación alta, señal débil y λ grande.** La ventaja de la relevante sobre una vecina es $(1 - \rho)|w^\star_b|$: 0,1 en el bloque 4 frente a 0,3 en el 1. La condición de irrepresentabilidad vale $0{,}9 < 1$: se cumple, pero con margen de 0,1.

2.3. Problema 6. Regresión reproducible sobre Airfoil

Decisiones metodológicas

Datos y auditoría. Se usó el conjunto *Airfoil Self-Noise* de UCI (id 291), guardado sin modificar en `data/airfoil_self_noise.dat`. Cada fila recibió un `id` igual a su posición en el archivo. Antes

de partir solo se revisaron formato, identidad y dominios físicos. No hay faltantes, duplicados exactos ni valores fuera de dominio, así que no se aplicó ninguna limpieza y se trabajó con las 1503 filas. El metadato de UCI que describe el ángulo como binario es incorrecto: toma 27 valores entre 0° y 22,2°.

Partición. Se reservó el 20 % para prueba con semilla 2026: 1202 filas de desarrollo y 301 de prueba. Las filas se agruparon por su contenido para que un duplicado exacto no pudiera quedar en ambos lados. Como no hay duplicados, la restricción se cumple sin efecto, pero queda garantizada por construcción. El EDA y todas las decisiones posteriores usan solo desarrollo.

Lo que el EDA aportó al modelo. Antes de mirar los datos planteamos tres hipótesis. La Tabla 9 resume qué mostró el desarrollo y qué decidimos con cada una.

Hipótesis	Evidencia en desarrollo	Decisión
El ruido tiene un máximo en la frecuencia	En escala log, la media sube hasta cerca de 1000 Hz y luego baja, igual en las cuatro velocidades. Asimetría de `frecuencia`: 2,07.	Representación alternativa con $\log_{10} f$ y $(\log_{10} f)^2$.
Más velocidad, más ruido	Medias de 124,2 a 125,9 dB entre 31,7 y 71,3 m/s ($n \geq 215$ por grupo). Curvas por frecuencia casi paralelas.	`velocidad` como término lineal, sin interacción.
`angulo` y `espesor` son redundantes	Spearman 0,87 entre ambas.	Conservar ambas; Ridge y Lasso tratan la redundancia.

Tabla 9: ¿Qué decisiones de modelado respalda el EDA?

Los valores fuera de los bigotes (62 en `frecuencia`, 100 en `espesor`) son mediciones válidas del diseño experimental y se conservaron.

Representaciones. Se compararon dos, ambas lineales en los parámetros:

- **Original:** las cinco variables estandarizadas.
- **Alternativa:** se reemplaza `frecuencia` por $\log_{10} f$ y se añade $(\log_{10} f)^2$. Dominio $f > 0$ (en los datos, $\log_{10} f \in [2{,}30;\ 4{,}30]$); unidades $\log_{10}(\text{Hz})$ y $\log_{10}(\text{Hz})^2$. Juntas permiten una parábola en log-frecuencia.

Estas transformaciones no estiman nada con los datos. Lo que sí se estima, la media y la desviación del escalador, se ajustó dentro del entrenamiento de cada pliegue.

Validación y selección. Antes de ver resultados fijamos: cinco pliegues sobre desarrollo (con mezcla y semilla 2026), los mismos para todos los candidatos; la grilla $\lambda \in \{10^{-3}, 10^{-2}, 10^{-1}, 1, 10\}$ para λ_2 en Ridge y λ_1 en Lasso, con la convención (4); el RMSE medio como criterio; y como

referencias la media (para RMSE) y la mediana (para MAE) del entrenamiento. El candidato regularizado es el Ridge o Lasso con menor RMSE medio. Dos candidatos empatan si difieren en menos de 0,01 dB, y entonces se prefiere el mayor λ y luego Ridge. Todos los ajustes de Lasso convergieron (`tol` $= 10^{-6}$).

Resultados esenciales

Representación	Modelo	λ	RMSE medio (dB)	Desv. entre pliegues
–	Referencia media	–	6,972	0,331
Original	OLS	–	4,854	0,156
Original	Ridge	10^{-2}	4,854	0,158
Alternativa	OLS	–	4,730	0,105
Alternativa	Ridge	10^{-3}	4,745	0,093
Alternativa	Lasso	10^{-3}	4,730	0,104
Alternativa	**Lasso**	$\mathbf{10^{-2}}$	**4,735**	**0,098**

Tabla 10: ¿Qué candidato predice mejor en validación cruzada? Selección de la tabla completa, que está en `resultados/airfoil_cv_resumen.csv`.

La representación alternativa baja el RMSE de OLS de 4,85 a 4,73 dB, y lo hace en cuatro de los cinco pliegues (en el quinto la diferencia es 0,003 dB). Entre los candidatos regularizados, Lasso con $\lambda_1 = 10^{-3}$ y con 10^{-2} empatan según la regla, y se eligió el de mayor λ. Con $\lambda \geq 1$ todos empeoran, y con $\lambda_1 = 10$ Lasso anula todos los coeficientes y coincide con la referencia. La desviación entre pliegues no es un intervalo de confianza, pero sí muestra que las diferencias entre los mejores candidatos ($\approx 0{,}01$ dB) son mucho menores que la variación entre particiones ($\approx 0{,}1$ dB).

Modelo (ajustado en todo desarrollo)	MAE (dB)	RMSE (dB)	R^2
Referencia media	5,309	6,597	0,000
Referencia mediana	5,260	–	–
OLS	3,448	4,483	0,538
Lasso ($\lambda_1 = 10^{-2}$)	3,438	4,459	0,543

Tabla 11: ¿Cómo se desempeñan los finalistas en prueba? Evaluación única, representación alternativa.

En prueba, OLS y Lasso quedan prácticamente iguales, y ambos reducen el RMSE de la referencia en unos 2,1 dB.

Modelo	Segmento	n	RMSE (dB)	Residuo medio (dB)
OLS	$f \leq 1600\,\text{Hz}$	150	5,137	+0,53
OLS	$f > 1600\,\text{Hz}$	151	3,722	−0,03
Lasso	$f \leq 1600\,\text{Hz}$	150	5,124	+0,52
Lasso	$f > 1600\,\text{Hz}$	151	3,680	−0,06

Tabla 12: ¿Dónde se equivoca más el modelo? El umbral es la mediana de la frecuencia en desarrollo.

El error es mayor en frecuencias bajas, donde además el modelo subestima en promedio medio decibel. Las tres frecuencias más altas (12 500 a 20 000 Hz) tienen residuos medios de 2,6 a 5,2 dB, aunque con solo tres mediciones cada una. Nada de esto se usó para reajustar los modelos.

Conclusiones

- **La representación importa más que la regularización.** Pasar a $\log_{10} f$ y su cuadrado, como sugirió el EDA, fue la única decisión con una mejora consistente entre pliegues.
- **La regularización casi no aporta en este caso.** Con unas 960 filas de entrenamiento por pliegue y seis variables, OLS ya es estable. Lasso fue elegido por la regla de desempate, pero la evidencia no lo distingue de OLS (0,006 dB en validación, 0,02 dB en prueba) y no eliminó ninguna variable. OLS sería igual de bueno y más simple de explicar.
- **Un modelo lineal aditivo se queda corto.** Con $R^2 \approx 0{,}54$ y residuos con estructura, falta capturar interacciones entre las condiciones del ensayo.
- **Alcance de la evaluación.** La partición aleatoria reparte mediciones individuales, así que casi todas las condiciones de prueba (cuerda, ángulo y velocidad) aparecen también en desarrollo, a otras frecuencias. Lo evaluado es interpolación dentro de ensayos conocidos. Para medir el desempeño en condiciones nuevas habría que dejar fuera ensayos completos o una cuerda o velocidad entera (por ejemplo, con `GroupKFold`); esa evaluación no se hizo y es esperable un error mayor.
- **Interpretación.** Los coeficientes describen asociaciones dentro de este diseño experimental, no efectos causales. Como `angulo` y `espesor` están muy relacionadas, el coeficiente de cada una depende de que la otra esté en el modelo.

2.4. Problema 7. Clasificación temporal y política de alertas

Decisiones metodológicas

Datos y partición. `generar_vuelos(n=9600, seed=2026)` sin modificar, con $Y = \mathbb{1}\{\texttt{min_retraso} \geq 15\}$. Solo se usan predictores conocidos dos horas antes de la salida: itinerario, pronósticos (no clima observado), reservas, tráfico planificado, aerolínea y origen. Tras ordenar por `fecha_prediccion`

se cortó en el 60 % y el 80 %, excluyendo las 24 filas (un día) previas a cada corte porque la etiqueta tarda menos de un día en llegar: entrenamiento 5736 filas (V0000–V5735), validación 1896 (V5760–V7655) y prueba 1920 (V7680–V9599), con 25 h entre períodos.

Auditoría y preparación. En entrenamiento, cuatro variables tienen cerca de 6 % de faltantes (22,9 % de las filas con alguno), la prevalencia es 2,44 % (140 retrasos) y el tráfico sube 0,38 desviaciones estándar a lo largo del período. Imputación (mediana o moda), estandarización y *one-hot* con `handle_unknown="ignore"` se ajustan dentro de cada entrenamiento.

Modelos y selección. Logística L_2 sin ponderar (implementación propia del problema 4) y ponderada con $a_c = N/(2N_c)$, recalculado en cada entrenamiento y con la pérdida normalizada por $\sum_n a_{y_n} = N$; el intercepto no se penaliza. Equivale a `LogisticRegression` con `class_weight="balanced"` y $C = 1/(\lambda_2 N)$ (coeficientes iguales hasta 6×10^{-5}). Se eligió por AP media en cuatro pliegues expansivos con `gap=24`, todos con ambas clases; en empate, primero sin ponderar y luego el mayor λ_2.

Resultados esenciales

	AP media		Log-loss media	
λ_2	Sin ponderar	Ponderado	Sin ponderar	Ponderado
10^{-3}	0,229	0,226	0,095	0,471
10^{-2}	0,236	0,238	0,096	0,462
10^{-1}	0,216	**0,247**	0,110	0,484
1	0,209	0,223	0,119	0,593
10	0,209	0,211	0,120	0,676
Prob. constante	0,026		0,120	

Tabla 13: ¿Qué modelo ordena mejor los retrasos en validación cruzada temporal?

Gana la logística ponderada con $\lambda_2 = 10^{-1}$, aunque su ventaja sobre la mejor sin ponderar (0,011) es menor que la variación entre pliegues ($\approx 0{,}09$). No emitir alertas logra accuracy de 0,974 con recall 0. En el contraexperimento de fuga, ajustar la preparación con todo el entrenamiento *bajó* la AP en tres de cuatro pliegues (Δ entre $-0{,}005$ y $+0{,}0002$): la fuga es una propiedad del procedimiento, no del resultado, y con unos 30 positivos por pliegue una diferencia así puede tener cualquier signo.

	Sin ponderar	Ponderado	Prob. constante
ROC-AUC	0,851	0,853	0,500
AP / área trapezoidal PR	0,392 / 0,389	0,394 / 0,392	0,039 / 0,520
Log-loss / Brier	0,126 / 0,032	0,535 / 0,178	0,169 / 0,038
Probabilidad media	0,030	0,392	0,024

Tabla 14: ¿Ordenan y estiman bien la probabilidad los candidatos en validación? Prevalencia: 0,039.

En validación los dos ordenan igual, pero el ponderado predice en promedio 0,39 frente a una frecuencia de 0,039; en la calibración por quintiles (cinco grupos efectivos, 379–380 casos cada uno) sobrestima en todos, mientras que el sin ponderar sigue la diagonal salvo en el último grupo. AP y área trapezoidal difieren poco en los modelos, pero mucho en la referencia constante (0,039 frente a 0,520), porque la interpolación lineal inventa un área que ningún umbral alcanza. Estos diagnósticos no cambiaron el ganador.

Conclusiones

- **Ponderar cambia la escala, no el orden.** El ganador está mal calibrado: su umbral de alerta debe fijarse sobre sus probabilidades en validación, no a partir de la prevalencia.
- **Accuracy engaña con clases desbalanceadas**: 97,4 % sin detectar ningún retraso.
- **La fuga se evita por procedimiento**, ajustando la preparación dentro de cada entrenamiento, no por el tamaño de la diferencia que produce.

3. Conclusiones generales

- **La regularización ayuda cuando domina la varianza.** En el problema 5, con 120 filas, 20 variables y solo cuatro relevantes, Lasso reduce el error de OLS a menos de la mitad; en Airfoil, con unas 960 filas por pliegue y seis variables, OLS ya es estable y la regularización no aporta. En ambos casos se cumple lo de la Parte I: el sesgo crece con λ y solo vale la pena si la varianza cae más.
- **Cada pregunta necesita su métrica.** Predecir bien no garantiza recuperar el soporte (problema 5), y ordenar bien no garantiza probabilidades calibradas (problema 7). Por eso cada decisión se tomó con un criterio fijado de antemano y el resto se usó solo como diagnóstico.
- **Las garantías vienen del procedimiento, no de la métrica.** Ajustar la preparación dentro de cada entrenamiento, separar en el tiempo con un día de hueco y reservar la prueba hasta el final evitan la fuga por construcción; el contraexperimento del problema 7 mostró que la métrica, por sí sola, no la habría revelado.

Referencias

[1] T. Hastie, R. Tibshirani, J. Friedman. *The Elements of Statistical Learning*. Springer, 2009.

[2] K. P. Murphy. *Probabilistic Machine Learning: An Introduction*. MIT Press, 2022.

[3] R. Tibshirani. Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B*, 58(1):267–288, 1996.